

ИНСТРУКЦИЯ ПОЛЬЗОВАТЕЛЯ

Программа для сбора и семантического анализа новостей

ОГЛАВЛЕНИЕ

1. [Установка программы](#)
 2. [Запуск программы](#)
 3. [Пункты меню](#)
 4. [Файлы с результатами](#)
 5. [Возможные ошибки и их решение](#)
 6. [Часто задаваемые вопросы](#)
-

1. УСТАНОВКА ПРОГРАММЫ

1.1. Требования к системе

- **Python** — версия 3.8 или выше
- **R** — версия 4.0 или выше
- **Интернет** — для парсинга новостей и скачивания модели R
- **Операционная система** — Windows 10/11, macOS или Linux

1.2. Установка Python-библиотек

Откройте терминал (командную строку) в папке проекта и выполните:

```
pip install -r requirements.txt
```

Или установите вручную:

```
pip install feedparser pandas
```

1.3. Установка R-пакетов

Откройте программу R и выполните:

```
install.packages(c("udpipe", "ggplot2", "dplyr", "wordcloud", "RC
```

Или через терминал:

```
Rscript -e "install.packages(c('udpipe', 'ggplot2', 'dplyr', 'wor
```

Примечание: При первом запуске R-скрипта автоматически скачается модель для русского языка (около 13 МБ). Это может занять 1-2 минуты в зависимости от скорости интернета.

2. ЗАПУСК ПРОГРАММЫ

2.1. Способ запуска

1. Откройте терминал (командную строку)
2. Перейдите в папку с проектом: `cd D:/project`
3. Запустите программу: `python start.py`

2.2. Структура папок после распаковки

```
project/
├── start.py                # Главный файл (запуск программы)
├── scripts/
│   └── parser.py          # Модуль парсинга новостей
├── r_scripts/
│   └── analyze.R          # Модуль семантического анализа
├── notes/
│   └── user_manual.pdf    # Этот файл
```

```
|— requirements.txt      # Список Python-библиотек
|— README.md            # Описание проекта
```

3. ПУНКТЫ МЕНЮ

После запуска программы вы увидите главное меню:

```
=====
      АНАЛИЗ НОВОСТНЫХ ТЕКСТОВ
      Парсинг + семантический анализ
=====

1. Парсинг новостей (Python)
2. Запустить анализ (R)
3. Открыть инструкцию
0. Выход

=====

Ваш выбор:
```

3.1. Пункт 1 — Парсинг новостей (Python)

Что делает: Собирает новости с 7 российских новостных сайтов (РИА, ТАСС, Lenta.ru, Коммерсантъ, Независимая газета, МК, OpenNet).

Как использовать:

1. Нажмите клавишу `1` и `Enter`
2. Выберите режим сбора:
 - **Режим 1** — собрать ВСЕ новости (берёт всё, что есть в RSS-лентах)
 - **Режим 2** — собрать новости с фильтром по дням (1-30 дней)
 - **Режим 3** — добавить новые новости к существующим (накопление данных)
3. Дождитесь окончания сбора

Результат: Файл `data/raw_news.csv` с колонками: `source`, `date`, `title`, `text`, `full_text`

3.2. Пункт 2 — Запустить анализ (R)

Что делает:

- Лемматизация текстов (приведение слов к нормальной форме)
- Фильтрация — оставляет только существительные, глаголы, прилагательные
- Удаление стоп-слов и коротких слов
- Подсчёт частотности слов
- Построение облака слов (PNG)
- Построение столбчатой диаграммы топ-15 слов
- Построение графика динамики упоминаний по дням

Как использовать:

1. Сначала выполните парсинг новостей (пункт 1)
2. Нажмите клавишу `2` и Enter
3. Дождитесь завершения анализа (1-3 минуты)

Результат: Файлы сохраняются в папку `output/` (см. раздел "Файлы с результатами")

3.3. Пункт 3 — Открыть инструкцию

Открывает этот PDF-файл с подробным руководством.

3.4. Пункт 0 — Выход

Завершает работу программы.

4. ФАЙЛЫ С РЕЗУЛЬТАТАМИ

После выполнения анализа в папке `output/` появятся следующие файлы:

Файл	Описание	Как открыть
<code>output/plots/wordcloud.png</code>	Облако слов — чем крупнее слово, тем	Любой просмотрщик изображений

	чаще оно встречается	
<code>output/plots/top15_words.png</code>	Столбчатая диаграмма — 15 самых частотных слов	Любой просмотрщик изображений
<code>output/plots/dynamics.png</code>	График динамики упоминаний ключевых слов по дням	Любой просмотрщик изображений
<code>output/tables/word_freq.csv</code>	Таблица частотности слов (слово, частота)	Excel, блокнот, любой текстовый редактор
<code>output/tables/dynamics.csv</code>	Таблица динамики (дата, слово, количество упоминаний)	Excel, блокнот
<code>output/report.txt</code>	Текстовый отчёт со статистикой анализа	Любой текстовый редактор

5. ВОЗМОЖНЫЕ ОШИБКИ И ИХ РЕШЕНИЕ

Ошибка: «FileNotFoundError: data/raw_news.csv not found»

Решение: Сначала выполните пункт 1 (парсинг новостей).

Ошибка: «Rscript не найден»

Решение: Установите R с официального сайта <https://cran.r-project.org> и добавьте R в переменную PATH.

Ошибка: «ModuleNotFoundError: No module named 'feedparser'»

Решение: Установите библиотеку: `pip install feedparser`

Ошибка: «Не удалось создать график динамики»

Решение: Для динамики нужно минимум 2 дня данных. Запустите парсинг за 3-7 дней или используйте режим накопления (режим 3).

Ошибка: «Нет новостей»

Решение: Проверьте интернет-соединение. Некоторые RSS-ленты могут быть временно недоступны.

Примечание: При первом запуске R-скрипта может появиться сообщение о скачивании модели. Это нормально, просто подождите 1-2 минуты.

6. ЧАСТО ЗАДАВАЕМЫЕ ВОПРОСЫ (FAQ)

Вопрос 1: Сколько новостей собирает программа?

Обычно 300-700 новостей за 3-7 дней в зависимости от доступности RSS-лент. Максимальное количество новостей из одного источника: Коммерсантъ (~589), Lenta.ru (~200), ТАСС (~100).

Вопрос 2: Почему динамика по дням не строится?

Для построения динамики нужно минимум 2 дня с новостями. Запустите парсинг за 7 дней или используйте режим накопления (режим 3) несколько дней подряд.

Вопрос 3: Как часто нужно запускать программу для накопления данных?

Рекомендуется запускать парсинг каждый день в режиме 3 (добавление к существующим). Через неделю у вас будет достаточно данных для анализа динамики.

Вопрос 4: Где хранятся собранные новости?

В файле `data/raw_news.csv`. Вы можете открыть его в Excel или блокноте.

Вопрос 5: Можно ли добавить другие источники новостей?

Да, добавьте новую функцию парсинга в файл `scripts/parser.py` и укажите её в списке `sources`.
